

Model Performance Across All Evaluations
(Values = Original, Colors = Normalized)

	ISD	Truthful QA	Cond. Safety	Length Ctrl	AQI
SFT_NI	0.126	-0.006 <i>+/-0.05</i>	0.002 <i>+/-0.01</i>	0.954 <i>+/-0.43</i>	52.0
SFT_I	0.142	0.012 <i>+/-0.07</i>	0.022 <i>+/-0.02</i>	1.017 <i>+/-0.02</i>	25.8
DPO_NI	0.217	-0.006 <i>+/-0.13</i>	0.015 <i>+/-0.02</i>	0.987 <i>+/-4.00</i>	18.0
DPO_I	0.389	-0.005 <i>+/-0.15</i>	0.489 <i>+/-0.03</i>	1.117 <i>+/-0.61</i>	11.8
PPO_NI	0.241	-0.026 <i>+/-0.11</i>	0.007 <i>+/-0.01</i>	0.983 <i>+/-4.13</i>	40.8
PPO_I	0.379	-0.009 <i>+/-0.28</i>	0.303 <i>+/-0.02</i>	1.069 <i>+/-0.58</i>	43.5
GRPO_NI	0.244	-0.034 <i>+/-0.15</i>	0.020 <i>+/-0.01</i>	1.008 <i>+/-4.67</i>	24.6
GRPO_I	0.385	0.011 <i>+/-0.27</i>	0.325 <i>+/-0.02</i>	1.100 <i>+/-0.76</i>	31.5
CITA_NI	0.204	-0.040 <i>+/-0.12</i>	0.009 <i>+/-0.02</i>	0.977 <i>+/-3.03</i>	28.6
CITA_I	0.367	0.013 <i>+/-0.19</i>	0.400 <i>+/-0.03</i>	1.141 <i>+/-0.73</i>	55.0

Normalized Score (per eval)

